

Sistema para Auditoria de Conformidade de Websites à LGPD com GraphRAG

**John Victor de Oliveira Atanazio, Flavio Mesquita Marinho Filho, Yuri Silva
Bezerra de Lima**

Centro de Informática (CI), Universidade Federal da Paraíba (UFPB)
João Pessoa, PB, Brasil

Abstract. *This paper presents a knowledge-based system for assisting the review of publicly available website policies under the Brazilian General Data Protection Law and information security standards. The prototype represents regulatory knowledge as a directed property graph and combines graph neighborhood retrieval, website evidence, and a language model to produce traceable assessments. The article describes the graph schema, data sources, processing pipeline, demonstration procedure, and results available in the project repository. The implementation supports a reproducible academic demonstration and provides a practical basis for further validation and extension.*

Resumo. *Este artigo apresenta um sistema baseado em conhecimento para apoiar a revisão de políticas disponibilizadas por websites segundo a Lei Geral de Proteção de Dados Pessoais e normas de segurança da informação. O protótipo representa o conhecimento regulatório em um grafo de propriedades dirigido e combina recuperação por vizinhança, evidências extraídas do website e um modelo de linguagem para produzir avaliações rastreáveis. São descritos o esquema do grafo, as fontes de dados, o fluxo de processamento, o roteiro de demonstração e os resultados disponíveis no repositório. A implementação oferece uma demonstração acadêmica reprodutível e uma base prática para validações e extensões futuras.*

1. Introdução

Políticas de privacidade, termos de uso e avisos de cookies reúnem informações relevantes para a transparência sobre o tratamento de dados pessoais. A leitura manual desses documentos exige localizar evidências dispersas e relacioná-las a dispositivos da LGPD e a controles de segurança. Nesse cenário, técnicas de geração aumentada por recuperação permitem fornecer conhecimento externo ao modelo de linguagem e conservar a origem dos fatos utilizados na resposta [Lewis et al. 2020].

O projeto LGPD Standards and Laws Analyzer for Websites aplica essa ideia ao domínio de conformidade digital. A aplicação recebe endereços de páginas públicas, coleta trechos relevantes, consulta um grafo regulatório e produz avaliações organizadas

em dez tópicos. O processamento pode utilizar um modelo local por meio do Ollama ou o serviço Gemini, e os resultados são apresentados em JSON, Markdown e em uma interface Streamlit.

O objetivo deste artigo é documentar as decisões de modelagem e arquitetura que permitem combinar grafo de conhecimento, modelo de linguagem e GraphRAG. Além da descrição do sistema, são apresentados um roteiro de demonstração, resultados observáveis nos artefatos versionados e limitações compatíveis com o estágio de protótipo acadêmico.

2. Modelagem do conhecimento

2.1. Esquema do grafo de propriedades

Foi escolhida a trilha de grafo de propriedades. A base persistente é o arquivo triplas.json, carregado em uma estrutura DiGraph da biblioteca NetworkX. Essa estrutura admite nós e arestas dirigidas com atributos, mas não mantém arestas paralelas entre o mesmo par ordenado [NetworkX 2025]. Na versão analisada, as 51 triplas resultam em 71 nós e 51 arestas, distribuídos em vinte componentes fracamente conexos.

Cada tripla possui origem, relação, destino e fonte. A origem representa uma norma, dispositivo ou conceito regulatório; o destino representa outro conceito, requisito ou evidência esperada. Durante a carga, os nós recebem o atributo tipo, com os valores ENTIDADE_NORMA ou REQUISITO_CONTROLE. As arestas mantêm relação e fonte. O esquema cria cadeias como (LGPD)-[EXIGE]->(LGPD_Art_18_Direitos_Titular)-[REQUER_EVIDENCIA]->(Canal_Atendimento_So licitacoes_Titular).

Tabela 1. Esquema lógico do grafo de conhecimento

Elemento	Representação	Propriedades principais
Nó normativo	Lei, artigo, norma ou controle	tipo = ENTIDADE_NORMA
Nó de requisito	Obrigação ou evidência esperada	tipo = REQUISITO_CONTROLE
Aresta dirigida	Vínculo entre dois conceitos	relação e fonte
Tópico de auditoria	Pergunta especializada do domínio	id, título, âncoras, termos e normas

Fonte: Elaborada pelos autores com base no código e em triplas.json.

2.2. Fontes, construção e carga

A base reúne documentos locais relacionados à LGPD, ISO/IEC 27001, ISO/IEC 27002, gestão de riscos e gestão de terceiros. A LGPD fornece princípios, direitos, deveres e regras aplicáveis ao tratamento de dados pessoais [Brasil 2018]. Para o tópico de incidentes, a Resolução CD/ANPD nº 15/2024 disciplina a comunicação à autoridade e aos titulares [ANPD 2024]. Os PDFs são processados por util_pdf.py e mantidos

como textos com indicação de página. O arquivo `populate_knowledge_texts.py` também prepara recortes normativos usados pelo pipeline.

O grafo pode ser ampliado de três formas: inclusão manual de uma tripla pela interface, extração de candidatas a partir dos textos por um modelo de linguagem e importação de Turtle/RDF com `rdflib`. A função de persistência deduplica registros pela combinação origem, relação e destino. Para reconstruir a base usada na demonstração, basta clonar o repositório e carregar `tripas.json`; a regeneração a partir dos documentos é executada pelos scripts `util_pdf.py` e `gerador_tripas.py`. A origem textual deve acompanhar cada aresta para que a recuperação preserve a fundamentação.

3. Arquitetura KG + LLM + GraphRAG

A arquitetura possui dois fluxos que se encontram no contexto enviado ao modelo. No primeiro, `util_scraper.py` obtém o HTML, remove elementos de navegação e transforma títulos, parágrafos, itens e células em registros com URL e posição lógica. Para cada tópico, palavras-chave selecionam até seis trechos. No segundo fluxo, `compliance_graphrag.py` carrega o grafo e parte de duas âncoras associadas ao requisito analisado.

A recuperação converte temporariamente o grafo dirigido em não dirigido e calcula, para cada âncora, uma vizinhança de raio dois. As arestas do subgrafo são serializadas como regras normativas com indicação de fonte. Esse procedimento corresponde a uma busca local em grafo. Ele difere da busca global por comunidades e resumos hierárquicos proposta por Edge et al. [2024], mas preserva o princípio central de recuperar relações estruturadas antes da síntese.




Figura 1. Fluxo de recuperação e síntese do sistema.

Fonte: Elaborada pelos autores com base nos artefatos do projeto.

O prompt reúne a pergunta especializada do tópico, as relações recuperadas e os trechos do website. O modelo devolve um objeto JSON com estado, evidência, referência normativa e justificativa. Os estados previstos são CONFORME, NAO_CONFORME e ATENCAO. Os dez tópicos podem ser processados em paralelo,

e `json_to_markdown.py` transforma a saída estruturada em relatório. A interface Streamlit expõe filtros, indicadores, fundamentação, visualização das triplas e arquivos para download.

Ollama permite manter a síntese no computador do usuário, enquanto o Gemini oferece uma alternativa em nuvem. Essa separação entre recuperação e geração facilita substituir o provedor sem alterar o grafo. Também permite inspecionar o contexto normativo antes da chamada ao modelo, aspecto importante para uma demonstração em que a resposta deve ser fundamentada no conhecimento simbólico.

4. Demonstração e resultados

4.1. Roteiro de demonstração

A demonstração pode ser realizada pela interface com as páginas de política de privacidade e termos de uso indicadas no README. O usuário escolhe o provedor, informa as URLs e inicia a análise. A aplicação transforma os dez tópicos em perguntas do domínio, recupera um subgrafo para cada uma e mostra a resposta ao lado do trecho do site e da referência normativa. Assim, é possível acompanhar o caminho pergunta, âncoras, relações, evidência e síntese.

Tabela 2. Exemplos de perguntas sustentadas pelo grafo

Pergunta do domínio	Âncoras e recuperação	Resposta apresentada
A política informa as bases legais e a finalidade?	Art. 7 e finalidade; vizinhança de raio 2	Estado, trecho, norma e justificativa
Há canal para exercício dos direitos do titular?	Art. 18 e canal de atendimento; raio 2	Estado e evidência com URL e linha
Existe procedimento de comunicação de incidentes?	Art. 48 e controle de incidentes; raio 2	Estado, relações do grafo e justificativa

Fonte: Elaborada pelos autores a partir dos tópicos AUD-002, AUD-003 e AUD-008.

No relatório de exemplo versionado no repositório, os dez tópicos foram processados e todas as respostas registraram alguma fundamentação textual. Nove itens receberam o estado CONFORME e um recebeu NAO_CONFORME. O artefato demonstra a geração do relatório completo, a contagem por estado e a rastreabilidade por URL e linha. Esses números descrevem apenas a execução armazenada e não constituem uma medida geral de desempenho.

A inspeção estrutural confirmou as 51 triplas, as vinte âncoras previstas e subgrafos com 12 a 15 nós para os dez tópicos. Esses dados mostram que a resposta utiliza um contexto retirado do grafo, e não somente os parágrafos coletados. A persistência em JSON facilita a conferência ao vivo: uma relação pode ser localizada no arquivo, visualizada na interface e comparada com a justificativa gerada.

4.2. Limitações e oportunidades de evolução

A recuperação de evidências do website é lexical e não utiliza índice vetorial. O modo de contingência também decide pela presença ou ausência de palavras-chave. Como evolução, recomenda-se combinar busca semântica, regras estruturadas e validação das citações. A base deve adotar vocabulário controlado, registrar a edição e o dispositivo correspondente a cada fonte e manter triplas geradas automaticamente como candidatas até revisão. Testes com políticas rotuladas permitirão medir precisão, revocação e F1.

O protótipo deve ser interpretado como apoio à triagem. Uma política pública não comprova, por si só, controles internos, contratos ou práticas operacionais. Por essa razão, a resposta final precisa continuar associada às evidências recuperadas e sujeita à avaliação humana. Essa delimitação não reduz o valor didático do sistema; ela torna explícito o papel de cada componente na arquitetura híbrida.

5. Conclusão

O projeto implementa os elementos centrais de um sistema especialista baseado em conhecimento: domínio definido, grafo persistente, recuperação de relações, modelo de linguagem como interface de síntese e respostas com referências. A modelagem como grafo de propriedades é adequada às conexões entre leis, artigos, controles e evidências. A organização modular e a interface Streamlit tornam a solução demonstrável e favorecem a inspeção dos resultados.

A contribuição acadêmica está na integração entre conhecimento simbólico e linguagem natural aplicada a um problema concreto. O sistema atende de forma substancial à proposta KG + LLM + GraphRAG.

Referências

- ANPD (2024). Resolução CD/ANPD nº 15, de 24 de abril de 2024. Regulamento de Comunicação de Incidente de Segurança. [Portal da ANPD](#). Acesso em: 5 ago. 2026.
- Brasil (2018). Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais, texto compilado. [Planalto](#). Acesso em: 5 ago. 2026.
- Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., Truitt, S. e Larson, J. (2024). From Local to Global: A Graph RAG Approach to Query-Focused Summarization. arXiv:2404.16130. [arXiv](#).
- Lewis, P. et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems, v. 33. [NeurIPS](#).
- LGPD Standards and Laws Analyzer for Websites. Repositório GitHub, commit 2d0d2d06f1d8. [Repositório](#). Acesso em: 5 ago. 2026.
- NetworkX Developers (2025). DiGraph: directed graphs with node and edge attributes. NetworkX documentation. [Documentação](#). Acesso em: 5 ago. 2026.